



CENTRO
UNIVERSITÁRIO

Análise Preditiva do Desempenho Escolar utilizando Algoritmos de Aprendizado de Máquina

Arthur Valmor Ferreira Brietzke · Gabriel Rios Miranda · Jean Matheus · Lucas Matheus M. B. Valim · Matheus Nogueira

TOLEDO, PR – BRASIL

1. INTRODUÇÃO

Contexto

Mineração de dados educacionais

Campo em crescimento significativo, permitindo extrair padrões ocultos em ambientes acadêmicos para apoiar decisões pedagógicas.

Alinhamento com ISO/IEC 25010

Em conformidade com a norma de qualidade de software, buscou-se garantir **adequação funcional** e **eficiência de desempenho**, priorizando precisão e confiabilidade nas estimativas das notas dos exames.

Dados e pipeline de transformação

6.607


Registros

Dataset *StudentPerformanceFactors.csv*, obtido no Kaggle

20

Variáveis

Features numéricas e categóricas; variável-alvo: nota do exame final



Pipeline automatizado implementado com a biblioteca Scikit-Learn para garantir integridade e padronização dos dados.

3. ALGORITMOS UTILIZADOS

Modelos preditivos implementados

Regressão linear múltipla

Ajusta o hiperplano que minimiza erros quadrados residuais. Abordagem rápida, computacionalmente eficiente, com coeficientes que revelam direção e magnitude da influência de cada variável.

Random forest regressor

Ensemble de dezenas ou centenas de árvores de decisão; previsão baseada na média das estimativas. Hiperparâmetros otimizados via busca em grade com validação cruzada.

 A estratégia metodológica confrontou uma abordagem paramétrica linear contra um algoritmo de ensemble capaz de capturar relações não-lineares.

4. RESULTADOS E DISCUSSÃO

Desempenho comparativo dos modelos





Regressão linear superior

Contrariando o pressuposto inicial, a Regressão Linear explicou melhor a variância da nota final. Seus resíduos concentraram-se mais próximos de zero; o Random Forest apresentou dispersão mais ampla nas extremidades da distribuição.

Variáveis de maior impacto


Frequência às aulas e **Horas de Estudo Semanais** exercem protagonismo quase linear sobre as variações das notas.

Desempenho comparativo dos modelos



4. RESULTADOS E DISCUSSÃO

Presença de Overfitting





Insistência no modelo de ensemble

Não querendo desistir do Random Forest, testamos uma pipeline unindo o pré-processamento completo dos dados ao modelo configurado com 300 árvores e profundidade ilimitada.

Impactos de um deslize

Houve uma grande melhora nas métricas, mas esse salto no desempenho não se deve aos hiperparâmetros do modelo, mas sim a um vazamento de dados.

Desempenho comparativo dos modelos



6. CONCLUSÕES

O que os dados revelam

Determinantes diretos

Assiduidade e volume de estudo são os principais fatores causais do desempenho estudantil.

Simplicidade vence

Algoritmos paramétricos simples demonstram maturidade suficiente para apoiar educadores na prática.

Recomendação institucional

Incentivar políticas ativas de retenção e presença em sala de aula nas escolas.

Rigor metodológico

Etapas de modelagem seguiram processos de escalabilidade e modularização, conferindo confiabilidade à solução.

Referências bibliográficas

ABNT NBR 10520

Associação Brasileira de Normas Técnicas. **NBR 10520:** Informação e documentação — Citações em documentos — Apresentação. Rio de Janeiro: ABNT, 2023.

ISO/IEC 25010:2011

Systems and software engineering — SQuARE — System and software quality models. Geneva: ISO, 2011.

Hastie, Tibshirani & Friedman

The Elements of Statistical Learning: Data Mining, Inference, and Prediction. 2. ed. New York: Springer, 2009.

Pedregosa et al.

Scikit-learn: Machine Learning in Python. **Journal of Machine Learning Research**, v. 12, p. 2825–2830, 2011.